# LAPORAN PRAKTIKUM TEKNOLOGI BIG DATA
# PERTEMUAN 2




Kelompok 8 :

| | |
|---|---|
| Trias Aldi Prasetia | (J0403241002)) |
| Raden Mas Galih Pradityo | (J0403241030) |
| Raihan Alma Putra | (J0403241075) |
| Risha Mufliha Safira | (J0403241094) |

**TPL B**

**TEKNOLOGI REKAYASA PERANGKAT LUNAK**

**SEKOLAH VOKASI**

**IPB UNIVERSITY**

**2026**

*Dataset* yang digunakan: ***E-Commerce Shopper Behavior (Amazon/Shopify Based)*** (Sumber: Kaggle)

## 1. Identifikasi Kebutuhan Sistem

1. Jenis data yang digunakan: ***Structured***.
2. Sifat data: ***Batch***.
3. Estimasi volume data:
    - Ukuran file: 244,95 MB.
    - Dimensi tabel: 1.000.000 baris x 60 kolom.

4. Tujuan analisis utama: **Menganalisis faktor-faktor yang memengaruhi keputusan belanja daring pelanggan.**

## 2. Komponen Arsitektur

Tabel 1. Komponen Arsitektur

| Komponen | Teknologi | Alasan Pemilihan |
|---|---|---|
| *Data Source* | Kaggle | Penyedia dataset publik yang andal dan terstruktur. |
| *Ingestion* | *Apache NiFi* | Otomasi aliran data dari sumber ke sistem penyimpanan secara efisien. |
| *Storage* | *HDFS* | Penyimpanan terdistribusi yang skalabel untuk data bervolume besar. |
| *Processing* | *Apache Spark* | Pemrosesan data dalam memori yang cepat untuk pembersihan dan transformasi. |
| *Analytics* | *Spark SQL* | Kemudahan analisis data menggunakan *query* SQL pada dataset besar. |
| *Visualization* | *Looker Data Studio* | Penyajian dashboard interaktif dan laporan ringkasan yang informatif. |

## 3. Diagram Arsitektur

Alur utama sistem mengikuti urutan *Data Source* → *Ingestion* → *Storage* → *Processing* → *Output*.




Gambar 1. Arsitektur Diagram

## 4. Deskripsi *Pipeline* Sistem

### 4.1. Latar Belakang Sistem

Perkembangan industri *e-commerce* yang pesat menghasilkan volume data pelanggan yang sangat besar setiap harinya, mulai dari data transaksi, riwayat penelusuran produk, hingga karakteristik demografis dan gaya hidup pelanggan. Data-data ini berpotensi besar dimanfaatkan untuk memahami pola perilaku belanja, namun jika hanya diolah secara manual atau menggunakan sistem konvensional, proses analisis akan memakan waktu lama dan sulit menangani data dalam skala jutaan baris. Oleh karena itu, dibutuhkan sebuah sistem *Big Data* yang mampu menampung, mengelola, dan menganalisis data pelanggan secara efisien dan terstruktur. Sistem ini dirancang untuk membantu pelaku bisnis *e-commerce* dalam memahami perilaku dan preferensi pelanggannya secara lebih mendalam, sehingga strategi bisnis seperti promosi, rekomendasi produk, dan retensi pelanggan dapat dirancang berdasarkan data (*data-driven*), bukan sekadar asumsi.

### 4.2. Sumber Data dan Karakteristiknya

Sumber data yang digunakan dalam sistem ini adalah *dataset* transaksi *e-commerce* yang diperoleh dari platform *Kaggle*, berjudul *E-Commerce Shopper Behaviour and Lifestyle*. *Dataset* ini bersifat *structured* (terstruktur) dengan format *CSV*, terdiri dari sekitar 1.000.000 baris data dan 60 kolom atribut. Atribut-atribut tersebut mencakup tiga kategori utama, yaitu

a. Data demografis pelanggan seperti usia, gender, negara, tingkat pendapatan, dan status pekerjaan
b. Data perilaku belanja seperti frekuensi pembelian mingguan, pengeluaran bulanan, metode pembayaran, tingkat *cart abandonment*, dan kategori produk yang disukai
c. Data gaya hidup dan psikologis seperti tingkat stres finansial, kualitas tidur, kesadaran lingkungan, dan skor kecenderungan *impulsive buying*. Karena data ini berupa kumpulan data historis yang sudah lengkap dan tidak berubah secara *real-time*, sifat data yang digunakan adalah *batch data*, bukan data *streaming*.

### 4.3. Mekanisme Ingestion

Proses *ingestion* dalam sistem ini bertugas untuk mengambil dan mengalirkan data transaksi *e-commerce* dari *source* data lokal ke dalam lingkungan penyimpanan terdistribusi. Teknologi yang dipilih untuk tahapan ini adalah *Apache NiFi*.

Mekanisme *ingestion* dilakukan secara *batch* sesuai dengan karakteristik *dataset* mentah (format *CSV* berukuran 244,95 MB). *Apache NiFi* dikonfigurasi menggunakan alur kerja (*dataflow*) berbasis *processor*:

A. *GetFile / FetchFile*: Mengambil berkas *CSV dataset E-Commerce Shopper Behavior* secara otomatis dari lokasi direktori lokal/*source*.
B. *PutHDFS*: Mengalirkan dan menuliskan *FlowFile* data mentah tersebut secara langsung ke dalam direktori *Hadoop Distributed File System (HDFS)*.

Penggunaan *Apache NiFi* memastikan alur transmisi data dari *source* ke *storage* berjalan secara andal, terpantau, dan dapat diandalkan untuk menangani penambahan volume data di masa mendatang.

### 4.4. Penyimpanan Data (*Data Lake/Database*)

Data yang telah melalui proses *ingestion* menggunakan *Apache NiFi* selanjutnya disimpan pada *HDFS (Hadoop Distributed File System)*, yang berperan sebagai *data lake* dalam arsitektur sistem ini. *HDFS* dipilih karena kemampuannya menyimpan data dalam volume besar secara terdistribusi di beberapa *node*, sehingga sistem tetap dapat menangani pertumbuhan data pelanggan yang terus bertambah dari waktu ke waktu tanpa mengorbankan performa. Selain itu, *HDFS* memiliki mekanisme replikasi data yang menjaga ketersediaan dan keandalan data meskipun terjadi kegagalan pada salah satu *node* penyimpanan. Data mentah yang tersimpan pada *HDFS* ini kemudian dapat diakses langsung oleh *Apache Spark* pada tahap *processing*, tanpa perlu proses transfer data tambahan, sehingga alur pengolahan data menjadi lebih efisien dan konsisten dengan pendekatan *Big Data* secara keseluruhan.

4.5. Proses Analitik

Tahap pemrosesan dan analisis data menggunakan kombinasi *Apache Spark* dan *Spark SQL* untuk menangani eksekusi *query* pada *dataset* skala besar (1.000.000 baris dan 60 kolom) secara efisien.

Langkah-langkah analitik yang dilakukan meliputi:

A. *Data Cleaning & Processing (Apache Spark)*: Membaca data mentah dari *HDFS*, menangani nilai yang hilang (*missing values*), menyesuaikan tipe data pada 60 atribut, serta melakukan transformasi data awal menggunakan memori terdistribusi (*in-memory processing*).
B. *Data Querying & Aggregation (Spark SQL)*: Menjalankan *query SQL* terstruktur untuk menganalisis faktor-faktor yang memengaruhi keputusan belanja pelanggan. Analisis dilakukan melalui *agregasi* data berdasarkan:
    a. Segmentasi Demografi: Pengelompokan total pengeluaran dan frekuensi belanja berdasarkan kelompok usia, gender, tingkat pendapatan, dan status pekerjaan.
    b. Pola Perilaku Belanja: Analisis hubungan antara *cart abandonment rate*, metode pembayaran favorit, dan kategori produk yang sering dibeli.
    c. Faktor Gaya Hidup & Psikologis: Pengujian korelasi antara *impulsive buying score*, tingkat stres finansial, dan pengeluaran bulanan pelanggan.

Hasil agregasi dari *Spark SQL* disimpan kembali dalam format terstruktur yang siap divisualisasikan.

4.6. Output dan Manfaat Sistem

Hasil akhir (*output*) dari *pipeline Big Data* ini disajikan dalam bentuk *dashboard* laporan interaktif menggunakan *Looker Data Studio*. *Visualisasi* terhubung dengan data hasil olahan *Apache Spark/Spark SQL*.

Output Sistem:

A. Visualisasi grafik demografi pelanggan dan kontribusinya terhadap total penjualan.
B. Metrik dan bagan proporsi *cart abandonment* serta preferensi metode pembayaran.
C. Matriks analisis faktor psikologis/gaya hidup terhadap kecenderungan *impulsive buying*.

Manfaat Sistem:

A. Keputusan Berbasis Data (*Data-Driven*): Membantu pelaku bisnis *e-commerce* memahami preferensi dan tren perilaku belanja pelanggan secara akurat berdasarkan 1 juta data transaksi.
B. Optimalisasi Strategi Pemasaran: Memudahkan penyusunan strategi promosi, alokasi *voucher*, dan kampanye retensi pelanggan yang terukur sesuai segmen gaya hidup dan demografi.
C. Efisiensi Pengolahan Data: Memangkas waktu analisis data berukuran besar melalui arsitektur *Big Data* terdistribusi yang responsif dan terintegrasi.